



COMPARACIÓN EVOLUTIVA DE PACIENTES COVID; COYOACÁN VS IZTAPALAPA, CDMX.

OPTIMIZACIÓN DE OPERACIONES



SEMESTRE 2021-1

INGENIERÍA EN SISTEMAS BIOMÉDICOS

FACULTAD DE INGENIERÍA

UNIVERSIDAD NACIONAL AUTONOMA DE MÉXICO

28/01/2021

ALUMNO: DIMAS RAMIREZ LUIS DANIEL

PROFESOR: DR. JORGE LUIS ROJAS ARCE

Índice

1.- DESCRIPCIÓN DE LA PROBLEMÁTICA QUE ORIGINÓ EL PLANTEAMIENTO DEL PROYECTO	2
2.-OBJETIVO DEL PROYECTO Y RESULTADOS ESPERADOS	3
3.- MARCO TEÓRICO DE OPTIMIZACIÓN DE OPERACIONES	3
4.- TRATAMIENTO DE DATOS	3
4.1.-Recolección de datos	4
4.2.-Visualización de datos.....	4
4.3.-Filtrado de datos	6
4.5.-Preparación de datos	7
5.-DESARROLLO DE LOS ANÁLISIS DE OPTIMIZACIÓN DE OPERACIONES.....	8
5.1.-Definición de los estados de la Cadena de Markov	8
5.2.- Diagrama de transición general	9
5.3 Cadena de Markov, Coyoacán.....	10
5.3.1.- Matriz de estado estable	10
5.3.2 Probabilidad de un paciente en estado ambulatorio al cabo de 3 meses	11
5.3.3 Probabilidad de un paciente hospitalizado al cabo de 3 meses	11
5.4 Cadena de Markov, Iztapalapa.....	12
5.4.1 Matriz de estado estable.....	12
5.4.2 Probabilidad de un paciente en estado ambulatorio al cabo de 3 meses	13
5.4.3 Probabilidad de un paciente hospitalizado al cabo de 3 meses	14
6.-RESULTADOS	14
6.1 Coyoacán	14
6.2 Iztapalapa	15
6.3 Coyoacán VS Iztapalapa	16
7.-CONCLUSIONES	16
8.-REFERENCIAS.....	18
9.-BIBLIOGRAFÍA.....	19
10.-CONSULTAS ELÉCTRONICAS.....	19

1.- DESCRIPCIÓN DE LA PROBLEMÁTICA QUE ORIGINÓ EL PLANTEAMIENTO DEL PROYECTO

La llegada oficial del COVID-19 a México en marzo 2020, marcó sin duda alguna una nueva etapa en la vida de todos los mexicanos. Una etapa complicada y retadora para la mayoría de nosotros, una situación extraordinaria, un tema del cual absolutamente todos conocen, una cuestión universal. A casi un año del primer “Lockdown”, y con la evolución del SARS-CoV-2 alrededor del mundo, hemos sido testigos de un sin número de nuevas investigaciones, nuevos métodos, nuevas “normalidades”, nuevas vacunas, nuevas noticias, incontables historias dramáticas y otras tantas trágicas, en fin, un sinfín de nueva información, nuevos datos. Desde hace varios años, es un hecho que cada día se generan exorbitantes cantidades de datos. Se estima que para el 2025 se crearán 463 exabytes¹ de datos cada día en el mundo [1]. La llegada del COVID-19 en el mundo, trajo una nueva ola de datos los cuales han estado siendo manipulados alrededor de todo el mundo para tratar de entender el comportamiento y consecuencias del virus SARS-CoV-2 a un nivel macro.

Desde hace casi 7 meses me encuentro tratando de mejorar mis habilidades y conocimientos sobre estadística, específicamente con el empleo de R Studio, principalmente por gusto y afinidad hacia esta área. Al estar continuamente informándome y leyendo sobre estos temas me di cuenta que un tema de moda y que presume ser el “futuro” es el Data Science. En el ambiente de los usuarios de R Studio es bastante normal utilizar este programa para hacer Data Science, por lo que sin querer, me fui sumergiendo en este tema. La ciencia de datos es la ciencia centrada en el estudio de los datos, se encarga de extraer información de grandes cantidades de datos. Data Science combina la estadística, las matemáticas y la informática para interpretar datos; el objetivo es tomar decisiones.[2]

Con este proyecto, logre unificar los conocimientos básicos que he adquirido sobre Data Science y emplear herramientas ingenieriles del área Investigación de Operaciones enfocándome en el problema global por excelencia de estos tiempos.

Para este trabajo utilice poco más de 72,800 registros de dos alcaldías, Coyoacán e Iztapalapa. Coyoacán porque es la alcaldía en la que actualmente resido e Iztapalapa debido a que es la alcaldía con mayor número de habitantes. Adicionalmente, son las alcaldías con las que se tiene mayor número de registros.

¹ 1 Megabyte – 1,000,000 bytes.

1 Exabyte - 1,000,000,000,000,000,000 bytes

2.-OBJETIVO DEL PROYECTO Y RESULTADOS ESPERADOS

Preparar y filtrar los datos adecuadamente para emplear cadenas de Markov como una herramienta de análisis para situaciones relacionadas con procesos estocásticos.

A partir de estos modelos podre establecer probabilidades de evolución del siguiente estado, tasa de mortalidad y tasa de recuperación del COVID-19 en pacientes residentes de dos diferentes zonas de la CDMX cuyo conocimiento se espera contribuya a la concientización de la situación actual en la que nos encontramos y posiblemente identifique de manera más concreta, en que zonas y bajo qué condiciones los pacientes necesitan mayor atención o educación para la salud.

3.- MARCO TEÓRICO DE OPTIMIZACIÓN DE OPERACIONES

Las cadenas de Markov, es un modelo estocástico conocido también como “proceso sin memoria” en el que se define que el estado presente depende únicamente del estado inmediatamente anterior. [3]

Estos modelos están definidos por las siguientes condiciones: son de tiempo discreto, con un número finito de estados, probabilidades de transición estacionarias, matriz $M \times M$, y sin presencia de valores negativos. Conforme va pasando el tiempo (periodos) se van generando cambios en los estados. Los cambios de estado están en función de términos probabilísticos y son representados en probabilidades de transición entre estados.

Frecuentemente, las Cadenas de Markov son utilizadas en el área de Investigación de Operaciones para describir y realizar inferencias sobre el comportamiento de sistemas a través del tiempo. La utilización de estos modelos ha resultado adecuada para modelar la dinámica de poblaciones, sistemas de espera, control de inventarios, mantenimiento y reemplazo de equipos y en apoyo a la toma de decisiones en administración, ingeniería y medicina [4,5,6].

Resulta evidente la gran utilidad que representa esta herramienta para modelar situaciones del entorno clínico; es decir, conocer el comportamiento en la cual una persona con “x” enfermedad evolucionará a través del tiempo.

4.- TRATAMIENTO DE DATOS

Para el desarrollo de este trabajo, utilicé R Studio.

4.1.-Recolección de datos

Los datasets fueron importados desde la página del Portal de datos de la Ciudad de México [7]. Importé dos; uno correspondiente a la alcaldía Coyoacán y el segundo correspondiente a Iztapalapa. Para los dos casos, los datos contemplan:

- ❖ Pacientes de los servicios de salud del SSA, IMSS, ISSSTE, PEMEX, SEDENA, SEMAR, ESTATAL, CRUZ ROJA, IMSS-OPORTUNIDADES, DIF, MUNICIPAL, UNIVERSITARIO y sector PRIVADO.
- ❖ Sexo femenino y masculino.
- ❖ Paciente detectado de manera ambulatoria y hospitalizado.
- ❖ Evolución de la enfermedad.
- ❖ Años 2020 y 2021.
- ❖ Resultado definitivo: positivo a SARS-CoV-2

Se obtuvo un total de 72,806 datos. De los cuales 21,939 corresponden a la alcaldía Coyoacán y 50,867 a la alcaldía Iztapalapa.

Existe una gran diferencia entre un dataset y otro, debido a la diferencia en el número de habitantes entre una alcaldía y otra. En el 2015, se registraron 608,479 habitantes en Coyoacán, mientras que en Iztapalapa se registraron 1,827,868 de habitantes.[8]

4.2.-Visualización de datos

A continuación, muestro parte del proceso llevado a cabo para familiarizarme con los datos. Solamente muestro partes del código empleado para el dataset de Coyoacán, sin embargo, el tratamiento para el dataset de Iztapalapa fue muy similar.

Importé la base de datos desde el archivo .csv almacenado en mi unidad, previamente descargado.

```
library(dplyr)

library(readr)

library(Biodem)

base_covid <- read_csv("base.csv")

#summary(base_covid)
names(base_covid)

## [1] "origen" "sector"
## [3] "cve_entidad_unidad_medica" "entidad_unidad_medica"
## [5] "delegacion_unidad_medica" "unidad_medica"
## [7] "fecha_de_registro" "sexo"
## [9] "entidad_residencia" "cve_entidad_residencia"
## [11] "municipio_residencia" "cve_municipio_residencia"
## [13] "localidad_residencia" "clave_localidad_residencia"
```

```

## [15] "tipo_paciente"          "evolucion_caso"
## [17] "fecha_defuncion"        "semana_defuncion"
## [19] "intubado"               "diagnostico_clinico_neumoni
a"
## [21] "edad"                   "nacionalidad"
## [23] "esta_embarazada"        "meses_embarazo"
## [25] "es_indigena"            "habla_lengua_indigena"
## [27] "ocupacion"              "servicio_ingreso"
## [29] "fecha_ingreso"          "fecha_inicio_sintomas"
## [31] "diagnostico_probable"   "fiebre"
## [33] "tos"                     "odinofagia"
## [35] "disnea"                 "irritabilidad"
## [37] "diarrea"                "dolor_toracico"
## [39] "calofrios"              "cefalea"
## [41] "mialgias"               "artralgias"
## [43] "ataque_al_estado_general" "rinorrea"
## [45] "polipnea"               "vomito"
## [47] "dolor_abdominal"        "conjuntivitis"
## [49] "cianosis"               "inicio_subito_sintomas"
## [51] "diabetes"               "epoc"
## [53] "asma"                   "inmunosupresivo"
## [55] "hipertension"           "VIH_SIDA"
## [57] "otra_condicion"         "enfermedad_cardiaca"
## [59] "obesidad"               "insuficiencia renal_cronica
"
## [61] "tabaquismo"             "recibio_tratamiento"
## [63] "recibio_tratamiento_antibiotico" "recibio_tratamiento_antivir
al"
## [65] "antiviral"              "fecha_inicio_tratamiento_an
tiviral"
## [67] "contacto_infeccion_viral" "contacto_aves"
## [69] "contacto_cerdos"        "contacto_animales"
## [71] "vacunado"               "fecha_estimada_vacunacion"
## [73] "toma_muestra"           "laboratorio"
## [75] "folio_laboratorio"       "resultado_definitivo"
## [77] "es_migrante"             "pais_nacionalidad"
## [79] "pais_origen"            "fecha_ingreso_pais"
## [81] "puerperio"              "dias_puerperio"
## [83] "antipireticos"          "unidad_cuidados_intensivos"
## [85] "linaje_influenza_tipo_b" "viaje_1"
## [87] "viaje_2"                "viaje_3"
## [89] "viaje_4"                "viaje_5"
## [91] "rango_de_edad"

#View(base_covid$fecha_de_registro)
#View(base_covid$fecha_defuncion)
#View(base_covid$tipo_paciente)
#View(base_covid$evolucion_caso)

#defuncion_confirmada <- base_covid$evolucion_caso[base_covid$evolucion_c

```

```
aso=="DEFUNCION"]

#base_covid %>%
  #filter(evolucion_caso=="DEFUNCION")
```

En el código anterior, solamente visualicé algunos datos para darme una idea de la forma en la que voy a organizarme.

La base de datos cuenta con 91 columnas, de las cuales, para el fin del desarrollo de Cadenas de Markov utilizaré la información de la columna "tipo_paciente" para establecer nuestro estado inicial, "evolucio_n_caso" para el estado siguiente, "semana_defuncion", "fecha_ingreso" para obtener algunos datos adicionales.

Ahora cree una nueva base de datos, a partir del análisis anterior, pero solamente con la información que me interesa para este trabajo.

4.3.-Filtrado de datos

En esta parte, realicé una nueva base, con las columnas objetivo y un análisis del promedio de semana de muertes de los pacientes registrados para establecer un número máximo de periodos para las cadenas de Markov.

```
bcovid <- select(base_covid, tipo_paciente, evolucion_caso, fecha_ingreso
, semana_defuncion)

head(bcovid)

##   tipo_paciente evolucion_caso      fecha_ingreso semana_defuncion
##   <chr>         <chr>         <chr>              <dbl>
## 1 AMBULATORIO  EN TRATAMIENTO  24/12/2020              NA
## 2 AMBULATORIO  EN TRATAMIENTO  30/11/2020              NA
## 3 AMBULATORIO  EN TRATAMIENTO  08/01/2021              NA
## 4 AMBULATORIO  SEGUIMIENTO TERMINADO 13/05/2020              NA
## 5 AMBULATORIO  EN TRATAMIENTO  17/12/2020              NA
## 6 AMBULATORIO  SEGUIMIENTO TERMINADO 24/07/2020              NA

mean_death <- filter(bcovid, semana_defuncion>0)

summary(bcovid$semana_defuncion)

##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.   NA's
##   1.0   17.0    29.0   28.5   45.0    53.0  21206

#bcovid %>%
  #filter(semana_defuncion>52)

#bcovid %>%
  #filter(semana_defuncion<2)
```

❖ 43 personas murieron en la primera semana después de ser ingresados.

- ❖ 40 personas murieron después de 13 meses.
- ❖ El promedio de muertes (en semanas) es de 28.5, alrededor de 6 meses.
- ❖ Un periodo estará constituido por 1 semana.

4.5.-Preparación de datos

Finalmente, para poder establecer las matrices de estados para la cadena de Markov, comencé a analizar los posibles estados para cada caso y para determinar sus probabilidades.

```
bcovid %>%
  filter(tipo_paciente== "AMBULATORIO", evolucion_caso=="EN TRATAMIENTO")

bcovid %>%
  filter(tipo_paciente== "AMBULATORIO", evolucion_caso=="SEGUIMIENTO DOMI
CILIARIO")

bcovid %>%
  filter(tipo_paciente== "AMBULATORIO", evolucion_caso=="DEFUNCION")

## # A tibble: 66 x 4
##   tipo_paciente evolucion_caso fecha_ingreso semana_defuncion
##   <chr>         <chr>         <chr>         <dbl>
## 1 AMBULATORIO DEFUNCION      20/05/2020      23
## 2 AMBULATORIO DEFUNCION      13/11/2020      48
## 3 AMBULATORIO DEFUNCION      12/06/2020      25
## 4 AMBULATORIO DEFUNCION      06/06/2020      24
## 5 AMBULATORIO DEFUNCION      28/04/2020      21
## 6 AMBULATORIO DEFUNCION      23/06/2020      28
## 7 AMBULATORIO DEFUNCION      11/06/2020      27
## 8 AMBULATORIO DEFUNCION      16/06/2020      29
## 9 AMBULATORIO DEFUNCION      01/01/2021       2
## 10 AMBULATORIO DEFUNCION      10/04/2020      17
## # ... with 56 more rows

bcovid %>%
  filter(tipo_paciente== "AMBULATORIO", evolucion_caso=="SEGUIMIENTO TERM
INADO")

bcovid %>%
  filter(tipo_paciente=="HOSPITALIZADO", evolucion_caso=="ALTA - MEJORIA"
)

bcovid %>%
  filter(tipo_paciente=="HOSPITALIZADO", evolucion_caso=="ALTA - VOLUNTAR
IA")
```



```

bcovid %>%
  filter(tipo_paciente=="HOSPITALIZADO", evolucion_caso=="ALTA - CURACION
")
bcovid %>%
  filter(tipo_paciente=="HOSPITALIZADO", evolucion_caso=="CASO GRAVE -")
bcovid %>%
  filter(tipo_paciente=="HOSPITALIZADO", evolucion_caso=="CASO NO GRAVE")
bcovid %>%
  filter(tipo_paciente=="HOSPITALIZADO", evolucion_caso=="ALTA - TRASLADO
")
bcovid %>%
  filter(tipo_paciente=="HOSPITALIZADO", evolucion_caso=="CASO GRAVE - TR
ASLADO")
bcovid %>%
  filter(tipo_paciente=="HOSPITALIZADO", evolucion_caso=="DEFUNCION")
bcovid %>%
  filter(tipo_paciente=="AMBULATORIO", evolucion_caso != "EN TRATAMIENTO
", evolucion_caso != "SEGUIMIENTO TERMINADO", evolucion_caso != "SEGUIMIE
NTO DOMICILIARIO", evolucion_caso != "DEFUNCION")

```

Estos filtros me permitieron cuantificar los posibles estados dada una condición previa, necesario para poder establecer la matriz

5.-DESARROLLO DE LOS ANÁLISIS DE OPTIMIZACIÓN DE OPERACIONES

5.1.-Definición de los estados de la Cadena de Markov

La definición de los estados la realicé con base en la información que me proporcionaba el dataset. Esta información nos daba indicadores sobre la manera en la que cada paciente evoluciona dado su estado inicial.

ESTADO	NOMBRE	DESCRIPCIÓN	NOTAS	RIESGO
1	Sano	Paciente que se encuentra fuera de peligro por COVID-19.	Estado recurrente y absorbente	Bajo
2	Ambulatorio	Paciente que fue diagnosticado con COVID-19 ó presentó los síntomas suficientes para determinar que tiene COVID-19	Estado transitorio	Bajo-Medio Medio

3	Domiciliario	Paciente que tiene COVID-19, pero se encuentra con tratamiento en casa debido a que ya no esta en riesgo ó no fue admitido en alguna unidad médica.	Estado recurrente y absorbente	Bajo-Medio Medio Medio-Alto Alto Grave
4	Hospitalizado	Paciente que ingreso a alguna unidad médica.	Estado transitorio	Medio-Alto Alto Grave
5	Defunción	Paciente fallecido.	Estado recurrente y absorbente	Fatal

5.2.- Diagrama de transición general

Para poder entender mejor la manera en la que se mueven nuestros estados, realicé este diagrama que muestra las posibles evoluciones.

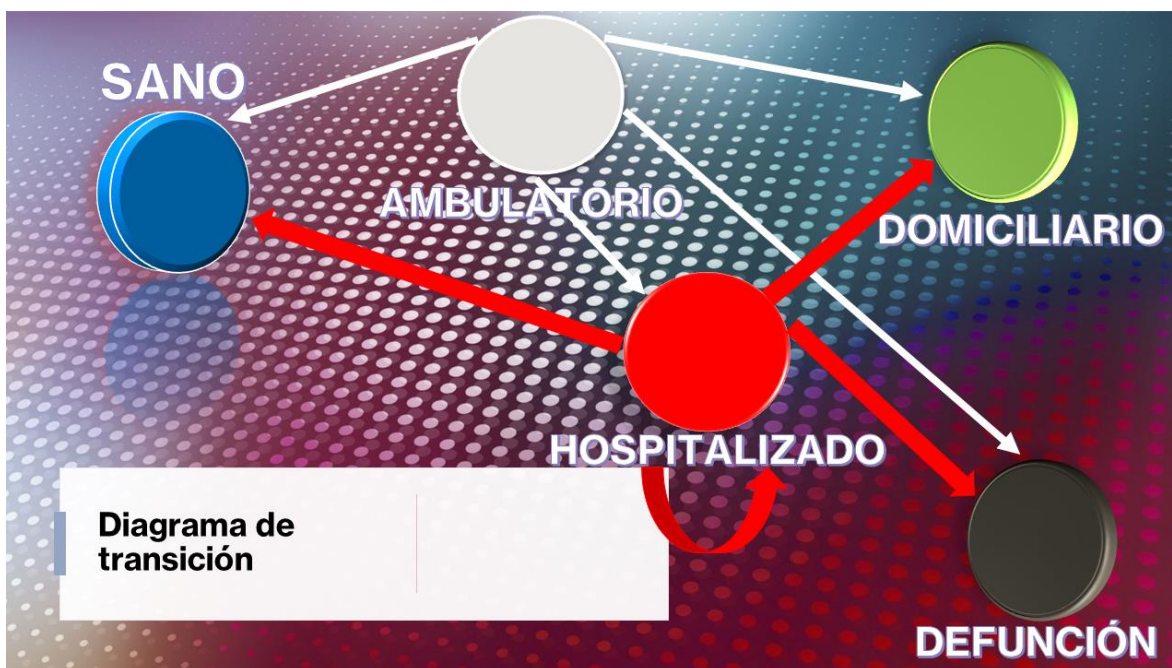


Imagen 1.-Diagrama de transición

5.3 Cadena de Markov, Coyoacán

Aquí quedan definidas las cadenas de Markov para la alcaldía Coyoacán, ya tienen formato en porcentaje.

```
da <- c(1,0,0,0,0, 1635/5051,0,11393/20204, 2135/20204, 34/5051, 0,0,1,0,
0, 16/1735, 0, 656/1735, 396/1735, 667/1735, 0, 0, 0, 0, 1)

matrizmarkov <- matrix(da, nrow = 5, ncol = 5, byrow = TRUE)
matrizmarkov

ESTADOS <- c("E1", "E2", "E3", "E4", "E5")
E1 <- c(1,0,0,0,0)*100
E2 <- round(c(1635/5051,0,11393/20204, 2135/20204, 34/5051)*100,2)
E3 <- c(0,0,1,0,0)*100
E4 <- round(c(16/1735, 0, 656/1735, 396/1735, 667/1735)*100,2)
E5 <- c(0,0,0,0,1)*100
Tablaf <- data.frame(rbind(ESTADOS, E1, E2, E3, E4, E5))
Tablaf
```

ESTADOS	E1	E2	E3	E4	E5
E1	100	0	0	0	0
E2	32.37	0	56.39	10.57	0.67
E3	0	0	100	0	0
E4	0.92	0	37.81	22.82	38.44
E5	0	0	0	0	100

5.3.1.- Matriz de estado estable

Para obtener la matriz de estado estable, eleve la matriz a una potencia n lo suficientemente grande. Esta propiedad permite conocer las probabilidades de estado estable, por lo que la matriz ya no cambia después de ciertos periodos.

```
estable1 <- mtx.exp(matrizmarkov, 10000000000000)
estable1
```

	E1	E2	E3	E4	E5
E1	1.00000000	0	0.00000000	0	0.00000000
E2	0.32496098	0	0.6156689	0	0.05937012
E3	0.00000000	0	1.00000000	0	0.00000000
E4	0.01194922	0	0.4899178	0	0.49813294
E5	0.00000000	0	0.00000000	0	1.00000000

Podemos observar que existen diferencias entre la matriz inicial y la matriz de estado estable. A partir de esta última matriz, podemos obtener la tasa de mortalidad y la tasa de recuperación para cualquier paciente.

5.3.1.1 Tasa de mortalidad

A partir de la matriz de estado estable, podemos encontrar la tasa de mortalidad general para la alcaldía Coyoacán. Esto se hace multiplicando el vector de entrada por la columna del estado 5, que es el estado para las defunciones.

❖ Vector de entrada

```
ventrada <- c(0,20204/21939,0,1735/21939,0)

mortalidad <- ventrada%%estable1[,5]
mortalidad*100

##           [,1]
## [1,] 9.406876
```

5.3.1.2 Tasa de recuperación

En este caso, en vez de utilizar la columna de defunciones, utilizare la columna en la que los pacientes están en un estado definido como “sano”.

```
recuperacion <- ventrada%%estable1[,1]
recuperacion*100

##           [,1]
## [1,] 30.02071
```

5.3.2 Probabilidad de un paciente en estado ambulatorio al cabo de 3 meses

En este caso, se plantea una situación en la que se cuestiona las probabilidades de un paciente con COVID-19 en estado ambulatorio después de 3 meses.

❖ 3 meses = 12 periodos

```
docep <- mtx.exp(matrizmarkov, 12)
docepf <- round(docep[2,]*100,2)
docepf

## [1] 32.50 0.00 61.57 0.00 5.94
```

Las probabilidades de que sane, se mantenga en ese estado, requiera tratamiento de manera casera, tenga que ser hospitalizado y muera, de manera consecutiva son: 32.5, 0, 61.57, 0, 5.94

5.3.3 Probabilidad de un paciente hospitalizado al cabo de 3 meses

En este caso, se plantea una situación en la que se cuestiona las probabilidades de un paciente con COVID-19 que se encuentra hospitalizado, después de 3 meses.

❖ 3 meses = 12 periodos

```
tresp <- mtx.exp(matrizmarkov, 12)
trespf <- round(tresp[4,]*100,2)
trespf
## [1] 1.19 0.00 48.99 0.00 49.81
```

Las probabilidades de que sane, se mantenga en ese estado, requiera tratamiento de manera casera, tenga que ser hospitalizado y muera, de manera consecutiva son: 1.19, 0, 48.99, 0, 49.81

5.4 Cadena de Markov, Iztapalapa

Aquí quedan definidas las cadenas de Markov para la alcaldía Iztapalapa, con formato en porcentaje.

```
da_iz <- c(1,0,0,0,0, 20749/47505,0,7145/47505, 19331/47505, 280/47505, 0
,0,1,0,0, 26/3362, 0, 1040/3362, 1016/3362, 1280/3362, 0, 0, 0, 0, 1)

matrizmarkov_iz <- matrix(da_iz, nrow = 5, ncol = 5, byrow = TRUE)
matrizmarkov_iz

ESTADOS <- c("E1", "E2", "E3", "E4", "E5")
e1 <- c(1,0,0,0,0)*100
e2 <- round(c(20749/47505,0,7145/47505, 19331/47505, 280/47505)*100,2)
e3 <- c(0,0,1,0,0)*100
e4 <- round(c( 26/3362, 0, 1040/3362, 1016/3362, 1280/3362)*100,2)
e5 <- c(0,0,0,0,1)*100
Tablaf_iz <- data.frame(rbind(ESTADOS, e1, e2, e3, e4, e5))
Tablaf_iz
```

ESTADOS	E1	E2	E3	E4	E5
e1	100	0	0	0	0
e2	43.68	0	15.04	40.69	0.59
e3	0	0	100	0	0
e4	0.77	0	30.93	30.22	38.07
e5	0	0	0	0	100

5.4.1 Matriz de estado estable

Matriz elevada a una potencia n lo suficientemente grande.

```
estable2 <- mtx.exp(matrizmarkov_iz, 10000000000000)
estable2
```

	[,1]	[,2]	[,3]	[,4]	[,5]
[1,]	1.00000000	0 0.00000000	0 0.00000000	0 0.00000000	
[2,]	0.44128491	0 0.3307985	0 0.2279166		
[3,]	0.00000000	0 1.00000000	0 0.00000000		
[4,]	0.01108269	0 0.4433078	0 0.5456095		
[5,]	0.00000000	0 0.00000000	0 1.00000000		

5.4.1.1 Tasa de Mortalidad

Multiplico el vector de entrada por la columna del estado 5, que es el estado para las defunciones.

```

ventrada_iz <- c(0,47505/50867,0,3362/50867,0)

mortalidad_iz <- ventrada_iz%%estable2[,5]
mortalidad_iz*100

##           [,1]
## [1,] 24.89142

```

5.4.1.2 Tasa de recuperación

Multiplico el vector de entrada por la columna del estado 1, que es el estado para las personas que se lograron recuperaron.

```

recuperacion_iz <- ventrada_iz%%estable2[,1]
recuperacion_iz*100

##           [,1]
## [1,] 41.28512

```

5.4.2 Probabilidad de un paciente en estado ambulatorio al cabo de 3 meses

❖ 3 meses = 12 periodos

```

docep_iz <- mtx.exp(matrizmarkov_iz, 12)
docepf_iz <- round(docep_iz[,]*100,2)
docepf_iz

## [1] 44.13  0.00 33.08  0.00 22.79

```

Las probabilidades de que sane, se mantenga en ese estado, requiera tratamiento de manera casera, tenga que ser hospitalizado y muera, de manera consecutiva son: 44.13, 0, 33.08, 0, 22.79

5.4.3 Probabilidad de un paciente hospitalizado al cabo de 3 meses

❖ 3 meses = 12 periodos

```
tresp_iz <- mtx.exp(matrizmarkov_iz, 12)
trespf_iz <- round(tresp_iz[4,]*100,2)
trespf_iz
## [1] 1.11 0.00 44.33 0.00 54.56
```

Las probabilidades de que sane, se mantenga en ese estado, requiera tratamiento de manera casera, tenga que ser hospitalizado y muera, de manera consecutiva son: 1.11, 0, 44.33, 0, 54.56

6.-RESULTADOS

6.1 Coyoacán

DESCRIPCIÓN	%
Tasa de mortalidad	9.406
Tasa de recuperación	30.02
Probabilidad de estar sano dado un caso ambulatorio	32.37
Probabilidad de tratamiento domiciliario dado un caso ambulatorio	56.39
Probabilidad de hospitalización dado un caso ambulatorio	10.57
Probabilidad de defunción dado un caso ambulatorio	0.67
Probabilidad de estar sano dado que esta hospitalizado	0.92
Probabilidad de seguir con tratamiento domiciliario dado que esta hospitalizado	37.81
Probabilidad de mantenerse hospitalizado dado que esta hospitalizado	22.82
Probabilidad de defunción dado que esta hospitalizado	38.44

Probabilidad de un paciente en estado ambulatorio al cabo de 3 meses

DESCRIPCIÓN	%
Probabilidad de sanar	32.5
Probabilidad de tratamiento casero	61.57
Probabilidad de ser hospitalizado	0
Probabilidad de defunción	5.93

Probabilidad de un paciente hospitalizado al cabo de 3 meses

DESCRIPCIÓN	%
Probabilidad de sanar	1.19
Probabilidad de tratamiento casero	48.99

Probabilidad de que se mantenga hospitalizado	0
Probabilidad de defunción	49.82

6.2 Iztapalapa

DESCRIPCIÓN	%
Tasa de mortalidad	24.89
Tasa de recuperación	41.28
Probabilidad de estar sano dado un caso ambulatorio	43.68
Probabilidad de tratamiento domiciliario dado un caso ambulatorio	15.04
Probabilidad de hospitalización dado un caso ambulatorio	40.69
Probabilidad de defunción dado un caso ambulatorio	0.59
Probabilidad de estar sano dado que esta hospitalizado	0.77
Probabilidad de seguir con tratamiento domiciliario dado que esta hospitalizado	30.93
Probabilidad de mantenerse hospitalizado dado que esta hospitalizado	30.22
Probabilidad de defunción dado que esta hospitalizado	38.07

Probabilidad de un paciente en estado ambulatorio al cabo de 3 meses

DESCRIPCIÓN	%
Probabilidad de sanar	44.13
Probabilidad de tratamiento casero	33.08
Probabilidad de ser hospitalizado	0
Probabilidad de defunción	22.79

Probabilidad de un paciente hospitalizado al cabo de 3 meses

DESCRIPCIÓN	%
Probabilidad de sanar	1.11
Probabilidad de tratamiento casero	44.33
Probabilidad de que se mantenga hospitalizado	0
Probabilidad de defunción	54.56

6.3 Coyoacán VS Iztapalapa

A continuación, se realiza una comparación entre las dos alcaldías de los factores de mayor interés.

FACTOR	Coyoacán (%)	VS	Iztapalapa (%)
Tasa de mortalidad.	9.40		24.89
Tasa de recuperación.	30.02		41.28
Probabilidad de hospitalización si te diagnostican COVID-19 y te encuentras en condiciones ambulatorias.	10.57		40.69
Probabilidad de tener que tomar un tratamiento domiciliario si te diagnostican COVID-19 y te encuentras en condiciones ambulatorias.	56.39		15.04
Probabilidad de defunción si te encuentras hospitalizado.	38.44		38.07
Probabilidad de morir después de 3 meses, estando hospitalizado.	49.82		54.56

7.-CONCLUSIONES

En cuestiones generales, puedo mencionar una posible diferencia en el nivel de vida² de una alcaldía respecto a otra, diferencia que podría repercutir en los datos obtenidos. Es decir; sería una buena manera de complementar este trabajo al hacer un análisis comparativo de educación, salarios, población por metros cuadrados en los cuales, casi me atrevo a asegurar que Coyoacán sería ligeramente mejor que Iztapalapa.

² Se entiende por nivel de vida la situación en términos económicos, mientras que la calidad de vida hace referencia a cuestiones como felicidad, tranquilidad y términos más subjetivos.

Tomando en cuenta factores socioeconómicos como los antes mencionados, observamos que la tasa de mortalidad de Coyoacán es de 9.40% mientras que en Iztapalapa es del 24.89%. Una cuestión bastante interesante es que la tasa de recuperación es mayor en Iztapalapa que en Coyoacán sin embargo si analizamos de manera conjunta la tasa de mortalidad vs la tasa de recuperación para cada alcaldía, nos daremos cuenta en cuestión de proporciones, es mucho mayor la tasa de recuperación en Coyoacán, casi el doble comparada con la de Iztapalapa.

Cuestión alarmante, debido a que la zona en la que vivimos afecta nuestras posibilidades de morir por COVID-19.

Otra situación alarmante es la probabilidad de ser hospitalizado después de ser diagnosticado o tener la presencia de todos los síntomas provocados por COVID-19 de manera ambulatoria; mientras que en Coyoacán es del 10.57%, en Iztapalapa es del 40.69%. Nuevamente notamos un gran contraste entre una cifra y otra. Para esta situación infiero que cuestiones como; una prueba para detectar la presencia del Virus SARS-CoV-2 a temprana evolución, una correcta información y entendimiento del proceso de la enfermedad puede repercutir en estas cifras.

En términos generales, podría poner el siguiente escenario sin poder afirmar de ninguna manera que es una situación real: en Coyoacán más personas están mejor informadas y entienden la situación de la enfermedad, por lo que son diagnosticadas cuando la enfermedad apenas está iniciando, situación que las lleva a tomar medidas rigurosas dentro de sus casas y con el tratamiento propuesto por un médico, mientras que en Iztapalapa hay menos personas correctamente informadas, lo cual lleva a que el diagnóstico se de en etapas más graves en las cuales ya es necesaria la hospitalización.

Por último, cuando analizamos las probabilidades una vez que el paciente ya ha sido hospitalizado, notamos que las probabilidades son muy parecidas. La probabilidad de defunción si te encuentras hospitalizado son del 38.44% y 38.07% para Coyoacán e Iztapalapa respectivamente. Y las probabilidades de muerte después de 3 meses, estando hospitalizado son de 49.82% y 54.56%.

Un aspecto importante a recordar es que las alcaldías se refieren al origen del paciente, sin embargo es necesario tomar en cuenta que una vez hospitalizados podemos encontrarnos en cualquiera unidad médica de la CDMX. Por lo tanto, una vez que ingresamos al hospital, nuestras probabilidades se igualan sin importar el origen del paciente. Teniendo en cuenta que una persona, en las condiciones actuales por las que atraviesa la ciudad, llega a la hospitalización cuando el riesgo ya es moderado-alto, alto ó grave, es congruente que las probabilidades se igualen a este punto.

Concluyo que es de vital importancia seguir invirtiendo de la salud preventiva y aplicar consecuencias o acciones correctivas más severas a personas que

infrinjan estatutos de salud importantes, en este caso, que quebranten las medidas sanitarias esenciales. En los resultados se hizo evidente que existe un gran contraste entre los porcentajes antes de hospitalización.

No es un secreto que el sistema de salud mexicano es deficiente, sin embargo se puede reducir el impacto de esas deficiencias si logramos comunicar de manera efectiva y a buen tiempo la educación para la salud. Con esto lograríamos reducir las entradas al sistema de salud mexicano haciendo que cada vez más personas se preocupen por no llegar a la enfermedad en vez de lidiar con la enfermedad o tratar de curarse de ella.

Gracias por leer este trabajo. 😊

8.-REFERENCIAS

- [1] Cuanta Data se genera en un día. Recuperado el 27/01/2021 a las 10:56 p.m. de <https://ia-latam.com/2019/04/18/cuanta-data-se-genera-en-un-dia/>
- [2] Neoland. “¿Qué es Data Science?”. Recuperado el 27/01/2021 a las 11:01 p.m. de <https://www.neoland.es/blog/que-es-data-science>
- [3] Facultad de Estudios a Distancia. “Unidad 2 – Cadenas de Markov”. Pp 1-3.
- [4] M.W. Carter. C.C. Price. “Operations Research: A practical introduction”. CRC Press. USA. 2001.
- [5] D.J. White. “Further real applications of Markov decision processes”. Interfaces, Vol. 18. No 5, pp. 55-61. 1988.
- [6] F.A. Sonnenberg, J.R. Beck. “Markov models in medical decision making”. Medical Decision Making, Vol. 13, pp. 322-338. 1993.
- [7] Portal de Datos de la Ciudad de México. Recuperado el 27/01/2021 a las 03:27 p.m. de <https://datos.cdmx.gob.mx/pages/home/>
- [8] INEGI. “Información por entidad”. Recuperado e 27/01/2021 a las 04:02 p.m. de <http://cuentame.inegi.org.mx/monografias/informacion/df/poblacion/default.aspx?tema=me&e=09>

9.-BIBLIOGRAFÍA

- Hillier Frederick S., Lieberman Gerald J.” *Introducción a la Investigación de Operaciones*”. Editorial MacGraw-Hill. Pp 673-695.
- Lieberman,G. “*Investigación de operaciones. México*”, Editorial McGrawHill
- Rojas Arce Jorge Luis. “TEMA 2”. Optimización de Operaciones.

10.-CONSULTAS ELÉCTRONICAS

- “*Sustituir valores dentro de un dataframe en R*”. Recuperado el 27/01/2021 a las 07:56 p.m, de <http://www.yoautorcientifico.com/?p=94>
- Huamaní Ninahuanca César Anderson. “*OPERACIONES CON MATRICES: Multiplicación, Determinante, Inversa, Factorización, Resolución de Ecuaciones y Gráfica*”. Recuperado el 27/01/2021 a las 07:57 p.m, de https://rpubs.com/Cesar_AHN/operaciones_con_matrices_multiplicacion_de_determinante_inversa_factorizacion_descomposicion_grafica
- Salazar Camila. “*Clase 6.- Limpieza de datos*”. Recuperado el 27/01/2021 a las 07:58 p.m, de <https://rpubs.com/camilamila/limpieza>
- “*Cambiar Valores*”. Recuperado el 27/01/2021 a las 07:58 p.m, de <https://datanicaragua.gitbook.io/r-tutorial/mutate>
- Neoland. “*¿Qué es Data Science?*” Recuperado el 27/01/2021 a las 10:30 p.m, de <https://www.neoland.es/blog/que-es-data-science>